대한산업공학회

2026 제22회 한국대학생 산업공학 프로젝트경진대회

온디바이스 AI 작업의
자원배정·스케줄링 정책



Overview

문제 여러 AI 요청이 제한된 연산 자원을 공유하므로,
응답 기한과 열·에너지 부담을 함께 고려해야 합니다.

방법 **실측 기반** 시뮬레이터에서 납기 정보를 활용해,
요청 선택과 자원배정 정책을 학습합니다.

평가 같은 요청 조건에서 규칙과 정책의 기한 준수·완료량·열·에너지를
비교합니다.

곤약젤리 노영훈 · 사선웅 · 이지민 · 이지안 · 조민규

온디바이스 AI의 개념과 확산

01 기기 안에서 실행하는 AI 추론

온디바이스 AI는 학습된 모델을 이용해 스마트폰 내부에서 입력을 처리하고 결과를 생성하는 기술입니다.

입력 사진·음성·글 → 스마트폰 내부 **AI 모델 추론** → **결과** 분류·요약 등

기기 내부 처리의 이점
통신 의존도 감소 · 입력 데이터의 외부 전송 감소

02 AI 작업과 연산 자원의 연결

AI 작업 → **지원 경로 확인** → **CPU·GPU·NPU 중 지원 자원에서 실행**

CPU · 범용 연산 GPU · 병렬 연산 NPU · 신경망 연산 가속

작업마다 지원되는 실행 자원이 다를 수 있습니다.

03 지원 기기와 모델의 확산 근거

Gemini Nano 제공 기기

1억 4천만 대 이상

모델이 제공되는 기기 수

[1] Google Android Developers (2026.07.21)

생성형 AI 지원 스마트폰 출하 전망

2024년 대비 2028년 약 3.9배

단위: 억 대



2024년 7월 전망 자료 기준 · 온디바이스 AI의 한 범주

[2] IDC (2024.07), 원문 그래프 재구성

온디바이스 AI는 **기기 내부의 연산 자원**을 활용하며, 생성형 AI 지원 스마트폰의 출하 확대가 전망됩니다.

자원 배정이 요청 응답과 기기 부담에 미치는 영향

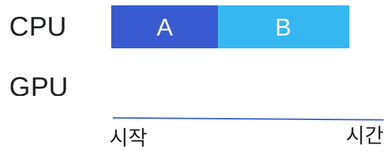
배정 자원 배정에 따라 달라지는 대기와 병행

동시 도착 · A 우선 · 병행 허용의 개념 예시

긴급 A(CPU·GPU 가능) + 일반 B(CPU만 가능)

긴급 A 일반 B

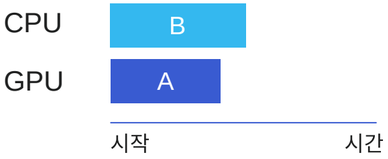
① A → CPU



B는 CPU가 반환될 때까지 대기

실행이 한 자원에 몰려
완료가 늦어질 수 있음

② A → GPU



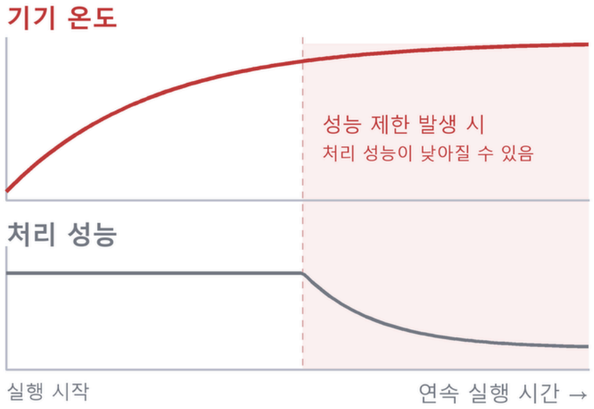
같은 시각에 B도 시작 (병행)

남아 있는 CPU에
B를 바로 배정할 수 있음

요청의 선택 순서가 같아도, 자원 배정에 따라 대기시간과 병행 가능성이 달라집니다

열 열 축적과 처리 속도

연산으로 온도가 상승하여, 열에 따른 성능 제한이 발생하면 처리시간이 길어질 수 있습니다.



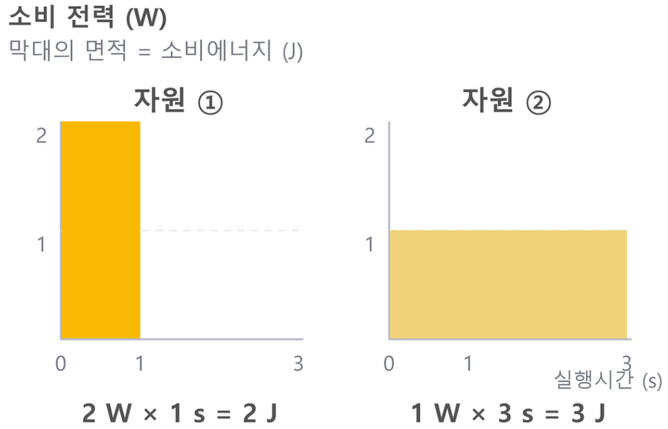
개념도 · 실제 측정값·단일 임계온도를 뜻하지 않음

근거: Android Developers · Thermal API

현재의 실행이 기기 온도와 이후 요청의 처리시간에도 영향을 줄 수 있습니다.

전력 실행 자원에 따른 에너지 소비

같은 요청도 자원마다 전력 · 시간이 다르다



동일 요청의 설명용 비교 · 실측값 아님

전력이 낮아도 오래 걸리면 에너지가 커질 수 있어, 자원 선택이 총 소비를 바꿉니다.

한 요청의 배정이 **다른 요청의 대기**와 **기기의 열·에너지 부담**에도 영향을 줄 수 있습니다.

기한과 기기 부담을 함께 고려하는 AI 작업 스케줄링

대기 요청·기기 상태

요청 A | 요청 B | 요청 C

요청별 남은 기한·중요도
자원별 예상 응답·점유시간

현재 기기 상태

지원 경로·자원 점유
관측 온도·실행 이력

우리가 개발하는 배정 정책

**지금 어떤 요청을,
어느 자원에서 시작할까?**

요청 1건 + 지원 자원 1개

지원·점유·병행 제약을 반영

배정·실행

요청별로 지원되는
실행 경로 중 선택

- CPU
- GPU
- NPU

정책 비교 기준

우선

- **기한 준수·완료량**
- 기한 위반·미완료

함께 고려

- **에너지·온도 부담**
- 모형상 예측 소비량
- 시간평균 AP 온도

자원 점유 변화가 다른 요청의 대기·병행·납기에 영향

배정할 때마다 자원 점유 상태를 반영하고, 새 요청 도착·자원 반환 등으로 상태가 바뀌면 배정을 다시 판단합니다.

산업공학적 정의 | 납기·공유 이종자원을 고려하는 동적 스케줄링

의사결정
어떤 요청을 어느 실행 경로에
지금 배정할 것인가

실행 제약
지원 경로·자원 점유와
허용되는 병행 조합

성과 기준
기한 위반·미완료를 우선 고려하고
예측 소비량·AP 온도를 함께 비교

요청–자원 배정을 반복하며, **기한 준수와 기기 부담의 상충**을 함께 다룹니다.

스마트폰은 작은 공장: 작업과 설비로 바라본 AI 요청 배정

공장 운영의 관점

공장의 구성 요소		스마트폰 AI
주문·작업	↔	AI 요청
납기·우선순위	↔	응답 기한, 중요도
이종 설비	↔	CPU·GPU·NPU
속도·성능·지원 작업이 서로 다른 설비		
작업 대기	↔	AI 요청 대기열

작업마다 조건이 다르고, 자원은 함께 씁니다.

스마트폰 내부의 작은 공장

대기 요청

B : GPU 지원

요청마다 지원 경로와 남은 기한이 다름

C : CPU 지원

CPU

요청 C 배정 가능

사용 가능한 실행 경로

GPU

요청 A 실행 중

요청 B는 대기

NPU

지원되는 요청만

해당 경로에서 실행

A의 GPU 점유 → B의 대기와 기한에 영향

※ 작동 원리를 설명하기 위한 개념 예시입니다. 지원 경로와 허용되는 병행 조합은 기기·작업마다 다릅니다.

스마트폰의 AI 요청 배정도, **납기와 공유 자원을 함께 고려하는 스케줄링 문제**입니다.

실측 기반 배정 정책 개발·평가 과정

실측·모형 구축

01
실측 자료 정리

처리·점유시간과 센서·실행 기록을 기기별로 정리

02
시뮬레이터 구축

요청·점유 재현 실측·가정 구분 구현·계산 점검

예측 확인·정책 개발

03
예측 확인

예측과 실측 대조 오차·적용 범위 점검

04
정책 학습(BC)

기기별 교사 규칙을 만들고, 신경망이 이를 모방 학습

정책 효과·해석

05
정책 효과 비교

요청·기한·초기 상태를 통일해 기준 규칙과 제안 정책을 비교

06
성과·상충 분석

요청 조건 별 기한 준수와 예측 소비·온도 해석

BC(Behavior Cloning): 교사 규칙이 고른 행동을 신경망이 모방하는 지도학습

③ 예측 확인 | 모형 예측 ↔ 실측 기록

모형이 실제 기기 반응을 얼마나 설명하는가?
확보한 실측과 예측을 대조하여
처리·점유·전력·온도의 오차와 적용 범위를 점검

⑤ 효과 확인 | 기준 정책 ↔ 제안 정책

같은 조건에서 배정 정책의 효과는 어떻게 다른가?
동일한 시뮬레이션 조건에서 기한·미완료와
예측 소비량·온도의 변화를 비교

확인 범위: 확보한 실측에서 예측 오차를 점검하고, A24·S26의 모형·설정 조건 안에서 정책 효과를 해석

예측 확인으로 **모형의 설명 범위**를 점검하고, 효과 확인으로 **배정 정책의 성과**를 비교합니다.

실측 기반 이산사건 기기별 시뮬레이션 설계

01 실측 자료의 반영

단계 시각	배정·출력·저장·반환 기록 → 처리·점유시간
실행·센서	작업·실행 경로·전력 대리지표·AP 온도
기기별 구성	각 기기 자료로 처리·소비·열 반응 구성

02 연구용 설정·가정

요청 조건	도착·기한·중요도는 연구용 입력
자원·실행	가상 자원 용량·비선점 실행·병행 제약
반응모형	병행 간섭과 소비·온도 변화를 추정해 적용

03 사건에 따른 상태 갱신

요청 도착·단계 종료·대기 종료·반환 시 갱신

요청 도착 → **대기·배정** → **작업 실행** → **응답 생성** → **자원 반환**

잔여 후처리·해제

빈 자원·지원 경로 확인 | 처리 중 자원 점유 | **기한 충족 여부 판단** | **자원 점유 유지** | **다음 요청 배정 가능**

$$t_{\text{다음}} = \min\{ t_j^{\text{사건}}, t_{\text{갱신}} \}$$

다음 사건 또는 계산 갱신 시각까지 전진하고 상태 갱신

$$E_{\text{예측}} = \sum_k P_k \times \Delta t_k$$

구간 평균 모형 전력 × 구간 길이의 합산

A24: J* · S26: API-J — 실측 배터리 에너지와 구분

실측과 연구용 설정을 구분한 모형에서, **배정에 따른 처리 과정과 기기 부담의 변화**를 재현합니다.

실측 기반 기기별 시뮬레이터 구축 및 예측 검증

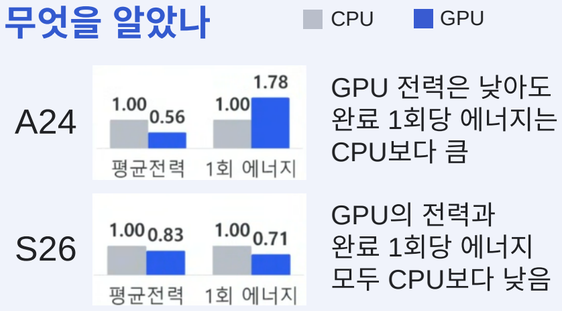
두 폰의 반응을 재서 기기별 시뮬레이터를 만들고, 만들 때 쓰지 않은 측정으로 예측을 확인했습니다.

01 두 폰의 실측

무엇을 쟀나

작업 사진 분류 · 물체 탐지
장치 CPU · GPU · NPU(S26)
처리 시간 요청 응답·자원 점유시간
소비·온도 실행·유휴 상태의 소비 대리지표와 온도 변화

무엇을 알았나



GPU 전력은 낮아도 완료 1회당 에너지는 CPU보다 큼

GPU의 전력과 완료 1회당 에너지 모두 CPU보다 낮음

기본 MobileNet · 100% 반복부하 · 60초 · 각 5회 중앙값
기기 전체 API 기반 추정 · CPU 1스레드 대비 배율

> 같은 자원도 기기별 득실이 다름

02 기기별 시뮬레이터 구축

요청 처리 · 사건 단위로 재생

도착 | 배정 | 실행 | 출력 | 저장 | 반환

시작한 작업은 중단하지 않음 · 응답 시점과 자원 반환 시점을 구분

A24 **CPU** **GPU** 분류·탐지 모두 선택

S26 **CPU** **GPU** **NPU** NPU는 분류만

기기 반응 모형

· 장치·작업별 처리 시간 · 동시 실행 시간
· 전력·기기 전체 온도: 상승·냉각
· 온도 변화와 처리시간·병행 간섭

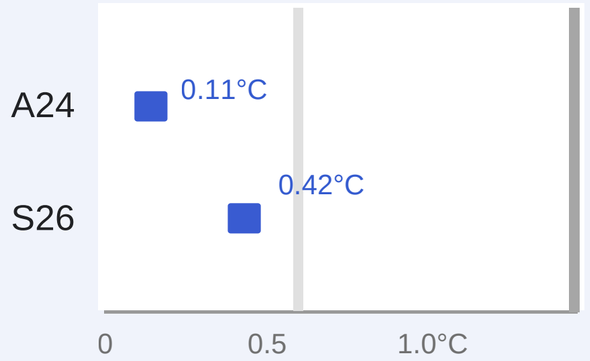
S26만 추가: 온도에 따른 처리 시간 변화

두 기기 시뮬레이터는 각각의 실측으로 따로 구축

03 시뮬레이터 예측 확인

구축에 쓰지 않은 실측과 대조

온도 예측의 평균 오차



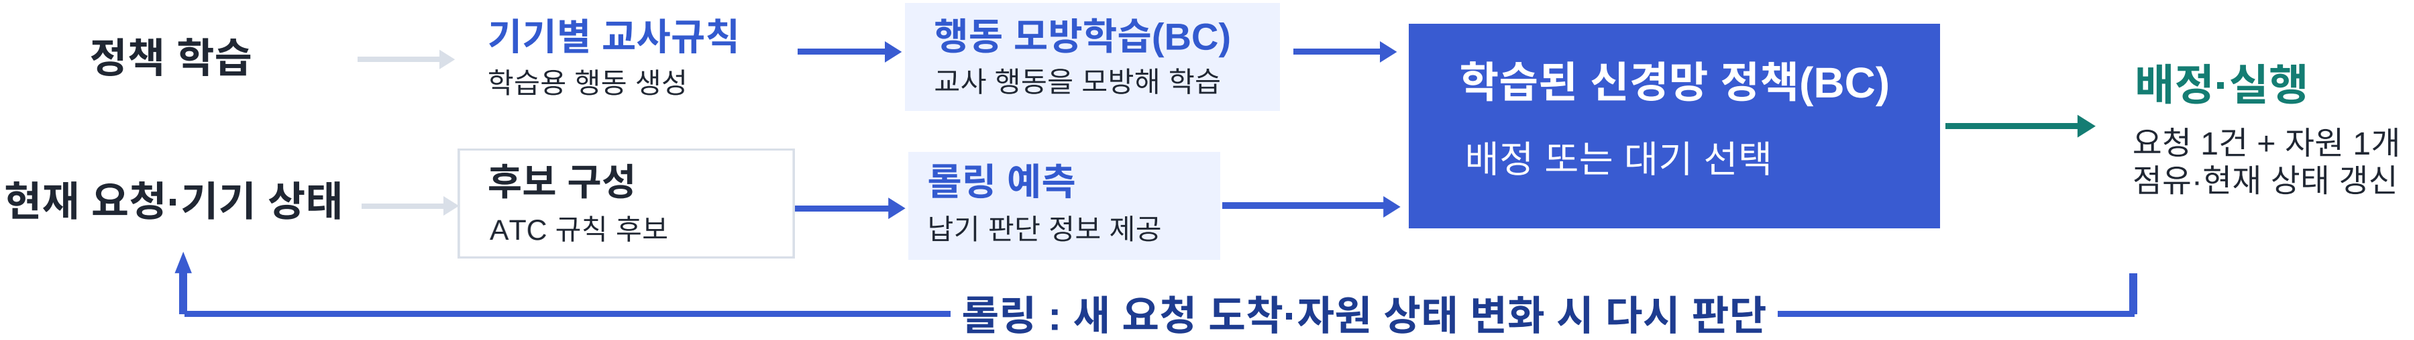
> 독립 검증에서 온도 평균 오차 1℃ 이내

적용 범위

측정해 본 부하·온도 범위 안에서만 사용

배정 정책의 작동 구조와 핵심 기법

작동 구조



핵심 개념과 우리 프로젝트의 활용

빈 자원과 실행 가능한 조합이 남으면 바로 한 번 더 선택(병행)

ATC **Apparent Tardiness Cost**	납기·중요도·처리시간을 반영하는 작업 우선순위 규칙	**대표 규칙과 함께 요청 후보를 구성하고 정책에 우선순위 정보 제공**
롤링 예측 **Rolling Forecast**	후보별 미래 처리 과정을 예측하고 상태 변화에 따라 갱신	**배정·대기에 따른 소비·열·납기 영향 예측**
교사규칙 **Teacher Policy**	스케줄링 원리와 기기별 규칙을 조합한 휴리스틱	**BC가 학습할 상태별 목표 행동 생성**
행동 모방학습(BC) **Behavior Cloning**	교사 정책의 행동을 모방하는 신경망 학습 방법	**교사 판단을 신경망 정책에 반영**

기기별 교사정책과 모방 학습

기기 특성을 담은 교사 규칙의 판단을, 신경망이 따라 배우게 했습니다.

① 교사 규칙 설계

기기마다 다른 특성을 규칙에 담음

A24 · 예측 비용 최소화

ATC로 후보를 고르고, 롤링으로
각 후보별 납기·응답·소비·열 영향을 예측

긴급 기한을 먼저 보호한 뒤
소비·열·지각·미완료·응답 비용의
합이 가장 작은 행동을 선택

S26 · 경로 선호 + 기한 우선

경로를 비교해 선호 경로를 정함
(분류는 NPU 중심, CPU는 배치용)

가능한 후보 중 기한이 빠른 요청 선택

**기기별 실행 프로필과 개발 진단을 바탕으로
행동 선택 기준을 구성**

② BC 학습 과정

교사의 선택을 보고 따라 배우는 지도학습

시뮬레이션 상태 수집
학습용 요청 조건에서

↓

교사의 정답 행동 생성
각 상태에서 교사가 선택한 행동 기록

↓

BC 학습
상태·후보 정보로 교사의 행동을 모방

↓

학습된 신경망 정책
가중치 고정 후 평가

실기기가 아닌 시뮬레이션 상태에서 생성

③ 학습한 정책 적용

학습후 가중치를 고정해 행동 선택에 사용

후보 구성과 영향 예측
ATC·대표 규칙으로 후보를 구성하고
롤링으로 후보별 이후 영향을 예측

↓

허용 후보 선별
지원 경로·자원 점유·병행 조건과
기한 보호 규칙을 반영해 후보를 제한

↓

BC의 최종 행동 선택
허용 후보 중 BC 점수가 가장 높은
요청·자원 또는 대기를 선택

상태가 바뀌면 다시 판단
새 요청·완료·대기 종료 때 후보와 예측 갱신

성과의 핵심은 교사 규칙이며, BC는 그 판단을 학습 가능한 정책으로 옮겼습니다.

새 기기에서는 교사 규칙만 그 기기에 맞게 바꾸고, 같은 절차로 다시 학습할 수 있습니다.

[시뮬] 비용 계수는 고정 설계값. 평가 시 BC 출력을 교사 행동으로 덮어쓰지 않음.
S26 정책은 기존 BC 가중치에 서비스 보완을 더해 사용 → 두 기기의 BC는 같은 방법 틀이지만 기기별로 따로 만든 모델.

공통 평가 기준과 기기별 비교 방법

납기·집계 **기준을 통일**하고, 각 기기 안에서 **성능을 고려한** 입력으로 정책을 비교했습니다.

같은 기기·입력에서는 요청·초기 상태·자원·모형·관측창을 고정하고 정책만 변경

01 공통으로 맞춘 기준

공통 항목	적용 기준
작업·기한	분류 = 긴급 0.8초 탐지 = 일반 2초
작업 구성	분류 50%·75% 시나리오 같은 입력을 각 정책에 동일 적용
정시율	기한 내 응답 수 ÷ 전체 도착 수 전체·긴급·일반을 각각 집계
지연·완료	입력별 P95의 평균 미응답·미완료도 함께 보고
소비·온도	같은 입력의 정책에 고정 관측창 적용 입력별 예측 소비·AP 평균을 동일가중
종료 규칙	공급 종료 +45초까지 배정 +90초까지 응답·자원 반환·소비 관측

02 기기별로 반영한 차이

구분	A24	S26
대표 입력	512건 · 8건 묶음 명목 부하 25%	1,024건 · 16건 묶음 명목 부하 85%
지원 경로	분류·탐지 CPU/GPU 탐지 GPU는 전이 가정 포함	분류 CPU/GPU/NPU 탐지 CPU
자원 가정	CPU 추론 슬롯 3개 GPU 슬롯 1개	경로별 추론 슬롯 1개 CPU 서비스 작업자 3개
기준선 배정	가용 CPU/GPU 중 예측 응답이 짧은 경로	GPU → NPU → CPU 고정 우선순위
정책 구현	50특징 BC 롤링·ATC + 대기 보완	32특징 BC 롤링·ATC + 서비스 보완
민감도 입력	요청 수·도착률·묶음 실행된 조합만 분석	부하·도착 패턴·분류비 확장 개발 32입력

기기 간 성능 순위가 아니라, 각 기기·입력 안에서 전체 배정 정책의 효과를 비교합니다.

S26: 긴급 기한을 모두 지키며 사용량과 온도를 낮췄다

같은 요청을 네 방법으로 처리했습니다. [S26 시뮬레이션 · 명목 부하 85% · 입력 4개 · 방법별 4,096건]

예측 사용량
−8.5%
FIFO 대비 · EDF 대비 −7.7%

칩(AP) 평균 온도
−0.87°C
FIFO 대비 · EDF 대비 −0.77°C

긴급 요청 기한 충족
100%
4,096건 모두 완료 · 전체 정시 97.07% (최고)

방법	사용량 (API-J)	평균 AP	전체 정시	일반 정시	긴급 P95
FIFO 도착순	840.5	39.43°C	96.92%	91.80%	0.37초
EDF 기한 빠른 순	833.3	39.34°C	96.70%	91.21%	0.34초
RR 작업 종류 번갈아	841.2	39.44°C	96.92%	91.80%	0.37초
롤링+ATC+BC	769.3	38.57°C	97.07%	92.19%	0.63초

API-J = 배터리 측정으로 만든 전력 모형의 값 · 정시율은 전체 도착 기준, 긴급 정시는 네 방법 모두 100%

세 기존 방법 모두보다 사용량·온도가 낮고, 정시 처리도 같거나 많음

우리 정책 3,976건 정시 (FIFO·RR보다 6건, EDF보다 15건 많음) · 일반 요청 지연 120건은 남음

기존 방법은 분류 장치를 GPU → NPU → CPU 순서로 고정

*EDF(Earliest Deadline First) = 기한이 가장 빨리 끝나는 요청부터 먼저 처리하는 방법
RR = 작업 종류를 번갈아 가며 처리(Round Robin)

무엇이 달랐나

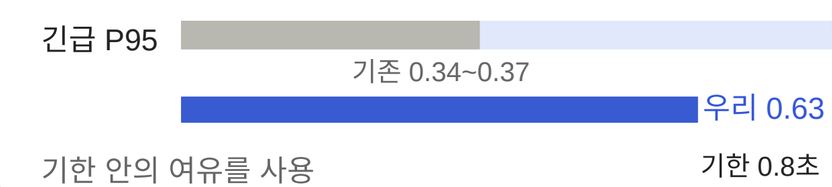
· 분류는 NPU 중심, CPU는 탐지용으로 확보

· NPU가 바쁘고 긴급 압력이 있으면 GPU 허용

· 롤링 예측·ATC 후보·BC 선택 + 서비스 보완

→ 정책 전체의 성과 (BC만의 효과로 보지 않음)

대가: 긴급 응답은 느려짐



*P95 = 95번째 백분위수. 요청 100건 중 95건이 이 시간 안에 응답했다는 뜻

A24: 정시율을 높이며 사용량과 온도를 낮췄다

같은 요청을 네 방법으로 처리했습니다. [A24 시뮬레이션 · 명목 부하 25% · 입력 4개 · 방법별 2,048건]
선택 조건: 입력당 512건 · 8건 묶음 · 분류 50%·75% 입력을 합산

예측 사용량

−1.32%

FIFO 대비 · EDF 대비 −1.12%

열(AP) 평균 온도

−0.29℃

FIFO 대비 · EDF 대비 −0.242℃

긴급 요청 기한 충족

100%

2,048건 모두 완료 · 전체 정시 100%

방법	사용량 (API-J)	평균 AP	전체 정시	일반 정시	긴급 P95
FIFO 도착순	476.2	32.1°C	93.41%	98.96%	0.91초
EDF 기한 빠른 순	475.3	32.04°C	97.85%	99.61%	0.79초
RR 작업 종류 번갈아	476.77	32.11°C	91.75%	99.74%	0.92초
롤링+ATC+BC	469,9	31.8°C	100%	100%	0.68초

J*: 입력당 평균 모형값 · 정시율: 전체 도착 기준 · P95: 입력별 값의 평균

세 기준선보다 합산 정시율은 높고, 예측 소비·평균 온도는 낮음

정시 2,045건: EDF보다 41건 많음 (+2.00%p) · 미완료 0건

교사 규칙도 정시율 100% · 소비 469.92 J* · 평균 AP 31.797℃

무엇이 달랐나

· ATC로 기한·중요도별 후보 구성

· 롤링 예측으로 응답·소비·열 비교

· BC로 작업과 CPU·GPU 배정 선택

정책 전체의 성과 (BC만의 효과로 보지 않음)

함께 볼 점: 일부 요청의 지각·지연

분류 75% 혼합: 긴급 1건 추가 지각

기준선 정시 100% → 우리 99.90% (1,024건)

일반 P95: RR 1.530초 → 우리 1.606초

결론: 기기 특성을 담은 규칙을 학습해 가상 폰에서 검증

기기별 실행 특성을 반영한 스케줄링 정책을 학습하고, 실측 기반 시뮬레이션에서 긴급 서비스와 자원 부담의 상충관계를 개선

① 실제 폰에서 확인한 사실 [실측]

- 같은 AI 작업도 기기마다 반응이 다름 (S26 GPU는 열에 약 2배 감속·회복)
- 이 차이를 실측으로 재서 기기별 가상 폰을 만들고, 새 측정으로 예측을 확인

② 시뮬레이션에서 확인한 성과 [롤링+ATC+BC]

- S26: 긴급 기한 100% 유지, 사용량 −8.5% · 온도 −0.87℃
- A24: 고부하 긴급 정시 65 → 80%, 소비 −2.2% · 온도 −0.59℃
- 대가: S26 긴급 응답 지연, A24 일반 요청 일부 양보

③ 시사점

- 핵심성과: 기기 특성을 담은 교사 규칙과 롤링·ATC 설계, BC는 이를 99.6% 재현
- 효과는 기기·부하에 따라 다르고, 긴급 서비스를 우선한 조건부 성과
  - **같은 방법이 S26에서는 기기 부담 감소, A24에서는 급한 서비스 확보로 나타남**
- AI 운영에 온도에 따라 처리 능력이 바뀌는 설비의 동적 스케줄링 관점을 적용

활용 방안

① **기기 재기** — 속도·전력·열 반응 → ② **교사 규칙 + BC** — 가상 폰에서 비교 → ③ **실제 폰** — 확인

새 기기는 교사 규칙만 바꿔 같은 절차로 다시 만듦

정책의 발전 방향

· 통합 정책 전체를 실제 폰에서 실행해 확인
· 실측과 맞도록 전력·열 모형 보정
· NPU 우선 기준과 같은 조건 비교로 효과 분리
· 일반 요청 보호 강화 (응답 지연 줄이기)
· 다른 기기·작업·실사용 부하로 확장

실사용 요청 기록 없이 합성 부하로 평가

기기·부하에 따라 달라지는 긴급 서비스 우선의 성과 → **기기를 재고, 특성을 담은 규칙을 학습해, 가상 폰에서 찾고 실제 폰에서 확인**

참고문헌 및 프로젝트 근거

외부 문제와 선행연구

[1] Samsung Research. 실시간 온디바이스 번역 개발 사례
[2] Ente Photos. Machine Learning
[3] Android Developers. Thermal API
[4] Band. MobiSys 2022
[11] Lin et al. AdaOper. arXiv, 2024
[12] Jeon et al. Phoenix. ACM TECS, 2026
[13] Google. 단말 내 요약·음성 전사 사례, 2026
[14] Google AI Edge. 로컬 미디어 검색 데모, 2026

직접 측정과 모형 근거

[5] A24 요청 정책 비교, 4쌍·8세션
[6–7] 공통 자원 측정 및 S26 회복 실험
[8] A24 192요청·8세션 예측 대조
[9] A24 조건·목적별 PC 정책 탐색
[10] S26 GPU 부하·회복·재가동 한 세션
프로젝트 저장소: github.com/mingyujo/D1Check

감 사 합 니 다